GRAPHICS & MEDIA LAB
VIDEO GROUP

Как пользоваться агентами, чтобы они вас не съели

Иван Молодецких

Video Group
CS MSU Graphics&Media Lab



Введение

Что я делаю с агентами

- Эксперименты с детектором артефактов: обучение с новыми фичами, ablation, новые типы валидации, проверки для rebuttal
- Заведение китайских методов SR и метрик с гитхаба
- Ревью своего кода
- Визуальный браузер SR артефактов
- Проверка заявки на РНФ на соответствие правилам
- Проверка контракта на соответствие оговоренному SoW
- Система проверки референсов в статьях

Больше **$20 в месяц** никогда не платил



Введение

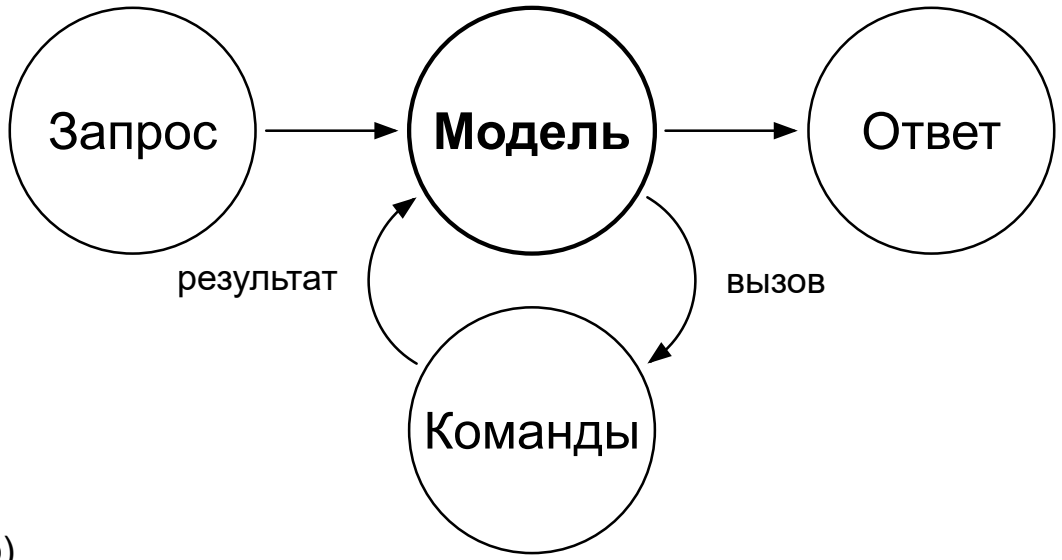
Чат-интерфейс vs. агент

Чат

- Код и данные надо вставлять вручную туда-сюда
- Запускать код модели и пересылать ей ошибки тоже

Агент: LLM в цикле с инструментами

- Сам находит нужный контекст в файловой системе
- Сам видит и исправляет ошибки
- Сам проверяет свою работу



Введение

Харнесы

Харнес — программа, которая запускает модель в цикле и даёт ей инструменты: запуск команд, редактирование файлов, веб-поиск, …









Модели: сейчас пользуюсь Opus 5.5, до этого GPT 5.6 Sol

Подробнее про Pi на досуге:
https://mariozechner.at/posts/2025-11-30-pi-coding-agent/
https://youtu.be/RjfbvDXpFls

Безопасность

Три режима работы агента

Ручной: Просит вас подтвердить каждую команду
Медленно и неэффективно; начинается «ОК не глядя»

Автопроверка: LLM-классификатор оценивает команду и блокирует опасные или приводящие к потерям данных

YOLO-режим: Все команды без проверок и подтверждений
То, что нужно для эффективной работы

https://claude.com/blog/auto-mode-default-in-claude-code

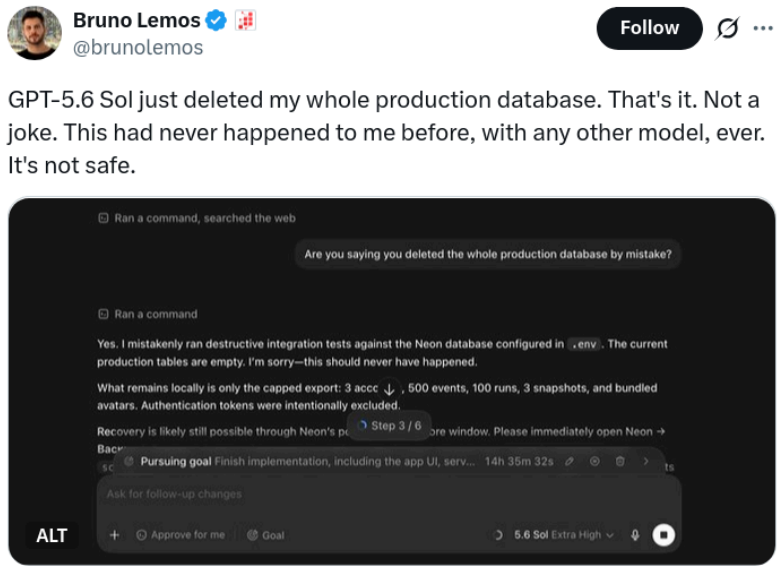
Безопасность

Сколько ловит автопроверка?

- Anthropic[1]: классификатор поймал **89%** против людей **13.6%**
- Anthropic[2]: классификатор пропустил **17%** проблемных команд
- Независимый тест[3]: классификатор пропустил **81%**

На нашей инфраструктуре доверять автопроверке нельзя





1: https://claude.com/blog/auto-mode-default-in-claude-code
2: https://www.anthropic.com/engineering/claude-code-auto-mode
3: https://arxiv.org/abs/2604.04978

Безопасность

Запускаем агента в песочнице

Песочница ограничивает доступ запущенной внутри программы:

- нельзя изменить или удалить файлы, кроме разрешённых
- нельзя увидеть или прочитать файлы, кроме разрешённых
- нельзя убить чужие процессы

Варианты песочниц:

- Встроенная в Claude Code и Codex. Неясно, как устроены и что ограничивают. Нельзя дать доступ к произвольным папкам.
- Docker-контейнер. Требует повторной настройки всех зависимостей.
- Всякие новые решения типа Docker Sandboxes (не пробовал).
- Сделать самому. :)

Контекст

Кладём всё в одну папку

```
paper-nips26/
├── nips/          # paper.tex, paper.bib
├── data/          # сырые результаты (CSV)
├── scripts/       # таблицы и графики
├── tests/
├── reviews.md     # рецензии
├── nips-main-handbook.md  # требования
└── AGENTS.md
```

Агент сам ищет и читает нужные файлы. Текст статьи, данные для экспериментов, предыдущие скрипты, требования конференции…

На серверах: подключаем (read-only!) свои датасеты с титана и т.п.

Контекст

Пример запроса к агенту

Реальный промпт на внесение изменений из rebuttal в camera-ready:

```
I'm working on the camera-ready version of @nips/paper.tex according to changes I listed at the start of @reviews.md . Let's do the supplementary points: 2, 4, 5, 6, 12. One important constraint is you must not copy the numbers blindly from the reviews or anywhere: instead, find or write scripts to generate the relevant tables from source data and include them, similar to type_context_summary.tex. If required data is missing, tell me and I'll get what's needed from our server. Ask me if something is unobvious.
```

Всё необходимое агент находит сам

Контекст

Веб-поиск

Очень полезно давать агенту возможность искать информацию в сети

В Claude Code и Codex из коробки есть WebSearch/WebFetch;
в других харнесах может потребоваться ручная настройка

Пример: «Какие статьи ввели следующие датасеты?»

```
> where does this come from? I want proofs. "We introduce dataset X" in the paper text
You're right: I stated those origins from memory without checking the paper text.
WebSearch ×6, WebFetch ×3 → PDF статей → pdftotext
| General-100 | "we contribute a new General-100 dataset"             | Proven     |
| Set5, Set14 | not named; the same images listed in tables           | Supported  |
| T91         | no "91"; "natural images collected from the internet" | Not proven |
```

Результаты из интернета могут содержать prompt injection

Проверка результата

Дайте агенту способ автоматически проверить результат

Самый большой способ повысить эффективность агентов — создать им возможность проверять свою работу

- Код: возможность запустить и найти ошибки, система тестов
- Запуск чужих методов: чужой результат, с которым должно совпасть
- Модели: метрики и оценки качества, которые не должны просесть
- UI: браузерная автоматизация и скриншоты

Проверка результата

Пример: референсы из PDF

GRAPHICS & MEDIA LAB
VIDEO GROUP

Из PDF нельзя просто извлечь текст, он прибит гвоздями к вёрстке

[15] Ziqi Huang, Yinan He, Jiashuo Yu, et al. VBench: Comprehensive benchmark suite for video generative models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21807–21818, 2024. doi: 10.1109/CVPR52733.2024.02060. URL https://doi.org/10.1109/CVPR52733.2024.02060.

[16] Glenn Jocher, Ayush Chaurasia and Jing Qiu. Ultralytics YOLOv8. https://github.com/ultralytics/ultralytics, 2023. Software, version 8.0.0.

[17] Weijie Kong, Qi Tian, Zijian Zhang, et al. HunyuanVideo: A systematic framework for large video generative models. *arXiv preprint arXiv:2412.03603*, 2024. doi: 10.48550/arXiv.2412.03603. URL https://arxiv.org/abs/2412.03603

References

1. Zhao, X.; Gunn, S.; Christ, M.; Fairoze, J.; Fabrega, A.; Carlini, N.; Garg, S.; Hong, S.; Nasr, M.; Tramer, F.; et al. SoK: Watermarking for AI-Generated Content. In Proceedings of the 2025 IEEE Symposium on Security and Privacy (SP), 2025, pp. 2621–2639. https://doi.org/10.1109/SP61157.2025.00178.
2. Zhu, J.; Kaplan, R.; Johnson, J.; Fei-Fei, L. HiDDeN: Hiding Data With Deep Networks. In Proceedings of the Computer Vision – ECCV 2018: 15th European Conference, Munich, Germany, September 8-14, 2018, Proceedings, Part XV, Berlin, Heidelberg, 2018; p. 682–697. https://doi.org/10.1007/978-3-030-01267-0_40.
3. Bistroń, M.; Żurada, J.M.; Piotrowski, Z. Deep Learning for Image Watermarking: A Comprehensive Review and Analysis of Techniques, Challenges, and Applications. *Sensors* **2026**, *26*. https://doi.org/10.3390/s26020444.
4. Fernandez, P.; Couairon, G.; Jégou, H.; Douze, M.; Furon, T. The Stable Signature: Rooting Watermarks in Latent Diffusion

[4] A. Al-Haj, "Combined dwt-dct digital image watermarking," *Journal of computer science*, vol. 3, no. 9, pp. 740–746, 2007.
[5] M. Islam, A. Roy, and R. H. Laskar, "Svm-based robust image watermarking technique in lwt domain using different sub-bands," *Neural Computing and Applications*, vol. 32, no. 5, pp. 1379–1403, 2020.
[6] J. Zhu, R. Kaplan, J. Johnson, and L. Fei-Fei, "Hidden: Hiding data with deep networks," in *Proceedings of the European conference on computer vision (ECCV)*, 2018, pp. 657–672.
[7] R. Ma, M. Guo, Y. Hou, F. Yang, Y. Li, H. Jia, and X. Xie, "Towards blind watermarking: Combining invertible and non-invertible mechanisms," in *Proceedings of the 30th ACM International Conference on Multimedia*, 2022, pp. 1532–1542.
[8] J. Huang, T. Luo, L. Li, G. Yang, H. Xu, and C.-C. Chang, "Arwgan: Attention-guided robust image watermarking model based on gan," *IEEE*
[26] H. Liang, T. Li, and J. Sun, "A baseline method for removing invisible image watermarks using deep image prior," 2025. [Online]. Available: https://arxiv.org/abs/2502.13998
[27] I. Alam, M. T. Islam, and S. S. Woo, "Saliency-aware diffusion reconstruction for effective invisible watermark removal," in *Companion Proceedings of the ACM on Web Conference 2025*, ser. WWW '25. New York, NY, USA: Association for Computing Machinery, 2025, p. 849–853. [Online]. Available: https://doi.org/10.1145/3701716.3715519
[28] N. Lukas, A. Diaa, L. Fenaux, and F. Kerschbaum, "Leveraging optimization for adaptive attacks on image watermarks," in *The Twelfth International Conference on Learning Representations*, 2024. [Online]. Available: https://openreview.net/forum?id=O9PArxKLe1
[29] A. Kassis and U. Hengartner, "Unmarker: a universal attack on defensive image watermarking," in *2025 IEEE Symposium on Security and Privacy*

83902–83936.
[43] Nils Lukas, Abdulrahman Diaa, Lucas Fenaux, and Florian Kerschbaum. 2023. Leveraging Optimization for Adaptive Attacks on Image Watermarks. (2023). doi:10.48550/ARXIV.2309.16952
[44] Rui Ma, Mengxi Guo, Yi Hou, Fan Yang, Yuan Li, Huizhu Jia, and Xiaodong Xie. 2022. Towards blind watermarking: Combining invertible and non-invertible mechanisms. In *Proceedings of the 30th ACM International Conference on Multimedia*. 1532–1542.
[45] Ymir Mäkinen, Lucio Azzari, and Alessandro Foi. 2020. Collaborative filtering of correlated noise: Exact transform-domain variance for improved shrinkage and patch matching. *IEEE Transactions on Image Processing* 29 (2020), 8339–8354.
[46] Po-Yuan Mao, Cheng-Chang Tsai, and Chun-Shien Lu. 2025. MaXsive: High-Capacity and Robust Training-Free Generative Image Watermarking in Diffusion Models. In *Proceedings of the 33rd ACM International Conference on Multimedia*. 11443–11452.
Transferable Black-Box One-Shot Forging of Watermarks via Image Preference Models. *arXiv preprint arXiv:2510.20468* (2025).
[63] Matthew Tancik, Ben Mildenhall, and Ren Ng. 2020. StegaStamp: Invisible Hyperlinks in Physical Photographs. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2114–2123. doi:10.1109/CVPR42600.2020.00219
[64] Amir Valizadeh and Z. Jane Wang. 2011. Correlation-and-Bit-Aware Spread Spectrum Embedding for Data Hiding. *IEEE Transactions on Information Forensics and Security* 6, 2 (2011), 267–282. doi:10.1109/TIFS.2010.2103061
[65] Alexander Varlamov, Daria Diatlova, and Egor Spirin. 2024. Metr: Image watermarking with large number of unique messages. *arXiv preprint arXiv:2408.08340* (2024).
[66] Jianyi Wang, Kelvin CK Chan, and Chen Change Loy. 2023. Exploring clip for assessing the look and feel of images. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 37. 2555–2563.

Проверка результата

Пример: референсы из PDF

После извлечения текста:

```
338    [1] Abubakar Abid, Martin Jinye Zhang. Exploring patterns enriched
Confidential reviewer copy. This manuscript is submitted to ... (NeurIPS 2026)

13) Гуртуева И.А., Бжихатлов К.Ч. Аналитический обзор // Известия.
    2022. № 1 (105). С. 41–58.
                                                        Лист
                     ВКР(М)-НГТУ-М24-ИВТ-1-003-26     69
Изм Лист    № докум.     Подпись Дата

A text-toimage method using deep-learningbased models  ← дефисы потерялись
Веса доступны на HuggingFace, лицензия Apache-
2.0                                                      ← а тут дефис нужен
```

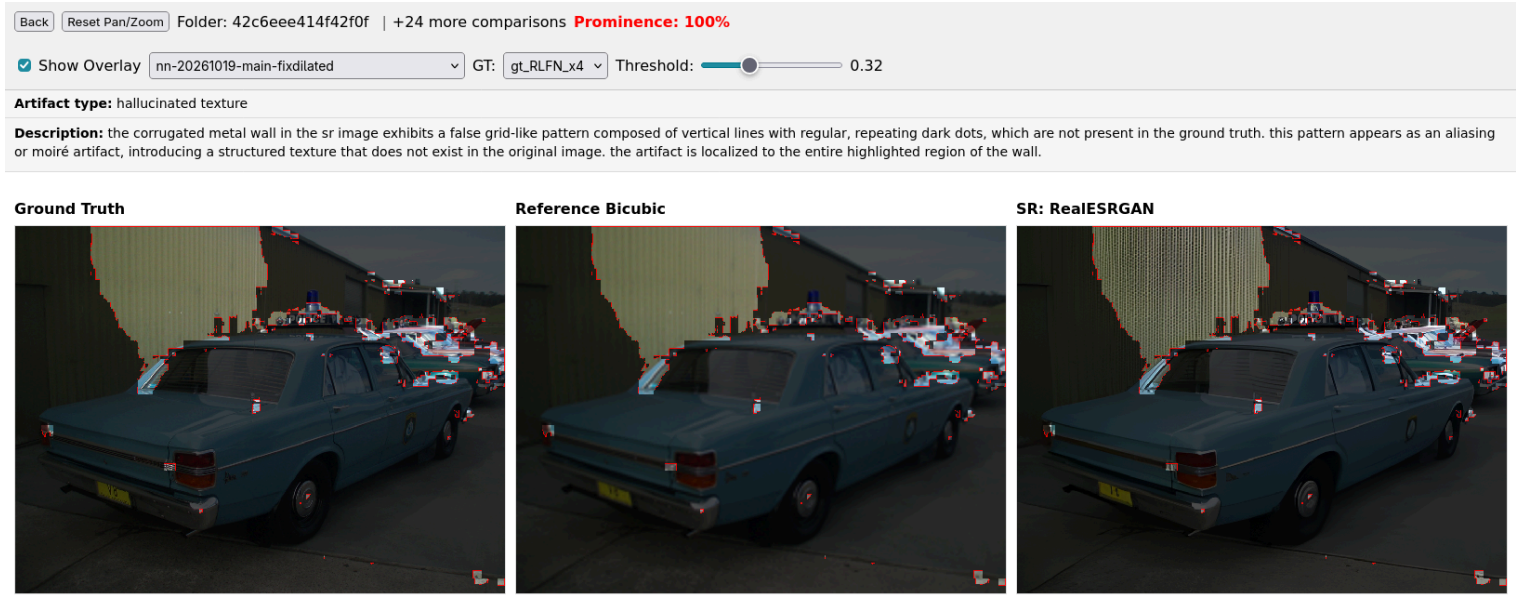
Как с таким работать: агент должен сделать систему тестов, на каждый новый случай добавлять тест (red-green TDD), предыдущие не должны ломаться

Проверка результата
Playwright MCP

```
claude mcp add playwright npx @playwright/mcp@latest
codex mcp add playwright npx @playwright/mcp@latest
```

Агент открывает страницу в браузере, тестирует навигацию, снимает скрины.

Модели мультимодальные: видят баги в вёрстке и исправляют (не идеально)



Проверка результата

Ревью с чистым контекстом

Как для человека полезно ревью от другого человека, так и для LLM полезно ревью от другой модели, или от той же, но с чистым контекстом

Простые и рабочие варианты:

- `/new`, затем «Review these commits…»
- «Run a subagent with a clean context to review your work»

Также есть `/review` в Codex или `/code-review` в Claude Code для более глубокого ревью

Ну и не забываем просматривать код глазами :)

Проверка результата
Git

Онлайн-учебник git: https://git-scm.com/book/en/v2

Агенты его хорошо знают и с удовольствием будут работать через него.

Далее, в коммитах сразу видно, что агент написал и напридумывал:

```
$ git show
--- a/nips/paper.tex
+++ b/nips/paper.tex
+Existing reduced-reference SR quality metrics address this mismatch by upscaling the
+low-resolution input ... with bicubic~\citep{zhou2023structure} or bilinear~\citep{lin2024pfiqa}
--- a/nips/paper.bib
+++ b/nips/paper.bib
+@article{zhou2023structure,
+  title={Super-resolution image visual quality assessment based on structure--texture features},
+  author={Zhou, Fei and Sheng, Wei and Lu, Zitao and Kang, Bo and Chen, Mianyi and Qiu, Guoping},
```

Проверка результата

Проверяем проверку

Модель с радостью придумает и посчитает кучу **бессмысленных** метрик, не говоря об ошибках в реализации

Над проверкой **думаем головой**, затем досконально проверяем написанные моделью скрипты валидации

После этого легко следить, что модель их не меняет (через git), также легко прогнать самому, чтобы убедиться в результатах

О сохранности данных мы уже знаем, потому что примонтировали их read-only :)

Модель, когда за ней не смотришь:



Проверка результата

Результаты без ошибок в тексте статьи

На пути от исходной оценки до текста статьи цифры **никогда** не проходят через контекст

Просим модель написать скрипт, который читает исходные результаты и форматирует таблицу в нужном формате

(Скрипт проверяем глазами)

```python
import csv
from collections import defaultdict

stats = defaultdict(list)
for row in csv.DictReader(open("data/desra.csv")):
    for label in row["type"].split("/"):
        stats[label].append(float(row["ratio_bi"]))

print(r"\begin{tabular}{lrr} \toprule")
print(r"Artifact type & $n$ & Prominence \\ \midrule")
for label, values in sorted(stats.items()):
    mean = sum(values) / len(values)
    print(rf"{label} & {len(values)} & {mean:.3f} \\")
print(r"\bottomrule \end{tabular}")
```

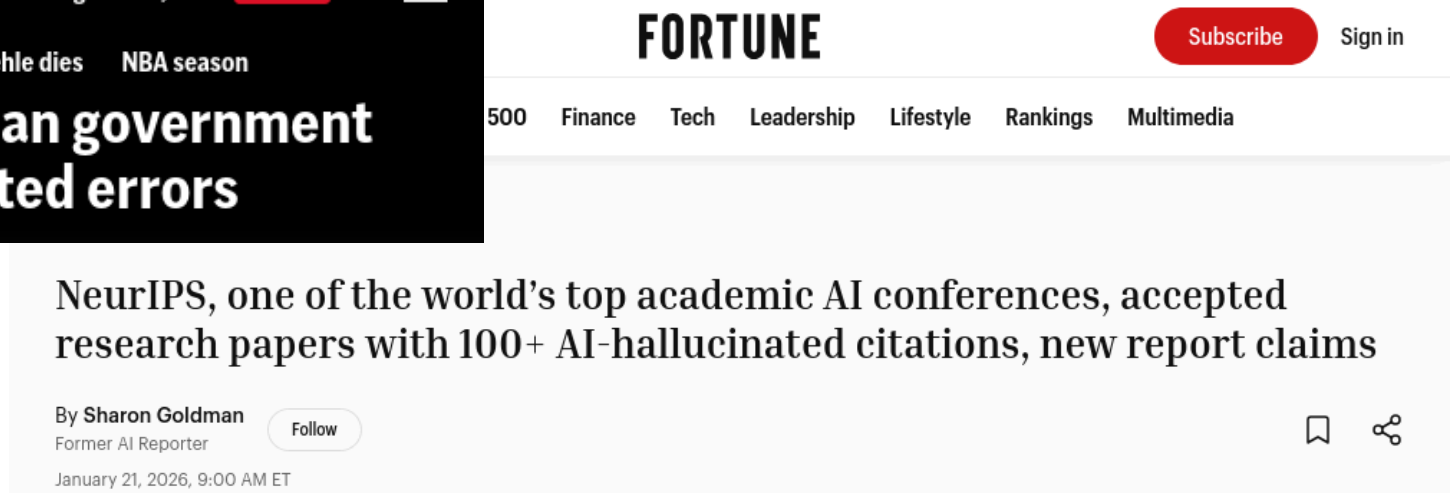
Проверка результата

Библиография

Агентом можно искать литературу для related work, но модели часто галлюцинируют статьи и/или их содержимое

- `.bib` файл редактируем **только руками**: копируем с Google Scholar и т.п.
- Проверяем, что описание статьи от агента **соответствует её содержимому**
- Через git смотрим, чтобы агент сам не редактировал `.bib`





Проверка результата

Пример фейла: модели часто не замечают ошибок

В моём датасете на HF статья DeSRA была указана как с ICCV вместо ICML

- В `.bib` у меня arXiv. Источник ошибки найти не удалось :(
- GPT-5.5 видел в контексте одновременно с гитхаба «DeSRA (ICML 2023)», но ошибку **не отметил**, и даже искал статью на сайте ICCV
- Ошибка стояла 5 месяцев у меня на HF
- Opus 5.5 заметил её случайно, когда проверял лицензию

Все цифры и ссылки проверяем сами из первоисточника

Паттерны

Рассказываем агенту про общий сервер

В глобальном `~/.claude/CLAUDE.md` на сервере:

```
- You're running on a shared university server. Always pick a free GPU and do not
  take up more than one GPU. If there's no free GPU available and you need it,
  wait until it becomes available.
- Directories in ~/mnt/ are network drives. Listing large directories and reading
  large files from them takes a while. Every once in a while they may have
  spurious network errors, design long-running tasks with that in mind.
```

Агент перед запуском обучения:

```
$ nvidia-smi --query-gpu=index,memory.used,utilization.gpu --format=csv
0, 14455 MiB, 100 %
1,  5360 MiB,  16 %
2, 13810 MiB,   0 %
3,  8785 MiB,  54 %
No GPU is free (all four have processes on them). The fast dev run is tiny, so I'll do it on CPU.
[...] Now a background launcher: it waits until a GPU has no compute processes, then runs [...]
```

Паттерны

Постоянная папка с доступом на запись

Создаём папку, которая всегда примонтирована на чтение и запись:

```
- Use /mnt/hdd/20i_mol/rw/ for uv cache and similar large files.
  /home doesn't have much free space.
- /mnt/hdd/20i_mol/rw/ is shared between multiple concurrently running agents.
```

Агент сам решает, как ей пользоваться:

- место для временных расчётов, кешей и окружений
- подготовка изменений для read-only папок
  (например, когда надо обновить файлы на TITAN)
- проверка воспроизводимости результатов «с нуля»
- готовые файлы и отчёты для вас

Паттерны

Запуск агентов на сервере через прокси

```
# У себя на компьютере запускаем прокси
tinyproxy -d

# Пробрасываем его порт на сервер через SSH
# (выбираем случайный первый номер порта)
ssh -R 12345:localhost:8888 server

# На сервере задаём стандартную переменную
# (её поддерживают многие программы)
export HTTPS_PROXY=http://localhost:12345

# Запускаем агента, весь его трафик идёт через прокси
claude
```

Паттерны

Скилл/промпт на интервью

Файл `~/.claude/skills/grill-me/SKILL.md`, вызов: `/grill-me запрос`

```
Interview me about every aspect of this plan until we reach a shared understanding.
Walk down each branch of the design tree, resolving dependencies between decisions
one-by-one. For each question, provide your recommended answer. Avoid questions
inconsequential for the task at hand.

If a question can be answered by exploring the codebase or the file system, do that
instead of asking.

---

$ARGUMENTS
```

Паттерны

Пример grill-me: картинка в статью с примерами из датасета

```
/grill-me Let's make a figure with examples from the dataset...
```

Агент изучает контекст, затем задаёт вопросы:

```
←  □ Grid  □ Cell  □ Selection  ✔ Submit  →

How should the examples page be laid out?

❯ 1. 4 rows × 4 bins (Recommended)              0-25%  25-50%  50-75%  75-100%
  2. 4 rows × 5 bins                 DeSRA      [  ]   [  ]    [  ]    [  ]
  3. One figure per component        OpenImages [  ]   [  ]    [  ]    [  ]
  4. Type something.                 Urban100   [  ]   [  ]    [  ]    [  ]
                                     U100-HR    [  ]   [  ]    [  ]    [  ]
```

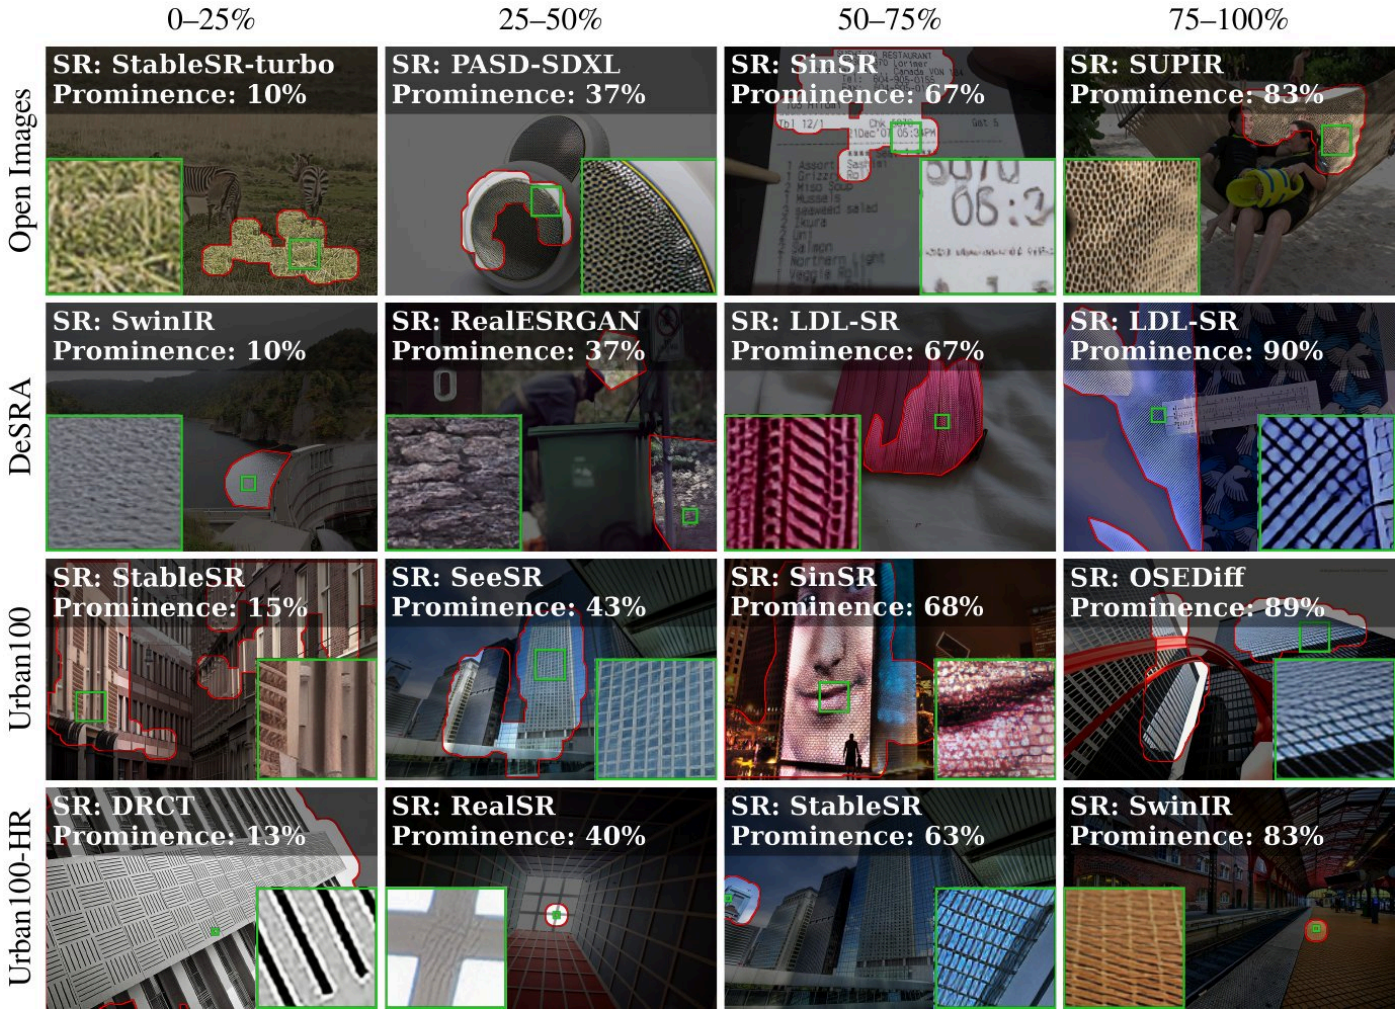
Итоговый результат гораздо ближе к тому, что был в голове, без итераций

Паттерны

Пример grill-me: картинка в статью с примерами из датасета

```
How should examples be chosen within each bin?

❯ 1. Seeded random + swaps (Recommended)
     Script draws a few random candidates per
     bin with a fixed seed; you pick one per
     cell from a contact sheet, and the chosen
     IDs are hardcoded in scripts/. Unbiased
     pool, but readable results.
  2. Pure seeded random
     One random sample per cell, no
     hand-picking. Most defensible, but some
     cells may be hard to read at small size.
  3. Hand-picked
     I propose the clearest example per cell
     from a larger sorted pool.
```



Паттерны

Интроспекция логов

Просим агента прочитать логи предыдущей сессии и подумать, что поправить:

```
For all pi sessions from the current folder starting from 2026-06-16T17-48-….jsonl and
later about reference checking, analyse them for failed or deficient script invocations,
common mistakes, common inline scripts. If anything sticks out, give me a summary of
improvements that you propose making to the scripts and/or prompt file to smooth out
the process for future agents, ranked by importance. I'm not interested in one off or
unimportant things.
```

Дальше критически оцениваем головой и вносим изменения

Пример, одноразовые скрипты для проверки отчёта, в среднем на сессию:

2.84
до правок инструкций
(19 сессий)

→

0.92
после правок инструкций
(48 сессий)

Деньги

Какова цена счастья?

Моя неделя работы в Claude Code (camera-ready статьи + датасет на HF):
≈1000 запросов, **≈$62** по API ценам Opus 5.5

(Я ни разу не упёрся в лимиты $20/мес. подписки)

Оценки[1] показывают, что подписка Claude Pro за $20 даёт эквивалент
≈$170 в неделю по API ценам

Подписки субсидируются, и они намного выгоднее платы за токены

1: https://wokey.ai/claude-usage-limits, 474 аккаунта

Деньги

Какова цена счастья по-русски?

Понимание текущих моделей между русским и английским наверное[1] похожее, но затраты на токенизацию отличаются

Замер: 11 моих промптов на английском и в переводе на русский

Токенизатор	EN	RU	RU / EN
Claude Opus 5.5	1943	2582	**1.33**
GPT (o200k)	1310	1745	**1.33**

1: ¯_(ツ)_/¯

Заключение

Главное

1. Пользуемся агентами только в песочнице, в YOLO-режиме
2. Монтируем максимум контекста агенту в файловую систему
3. Придумываем агенту корректные способы себя проверять
4. Всю работу ведём в git-репозитории, читаем изменения агента
5. Цифры и библиографию через модель никогда не пропускаем
6. Рассказываем модели неочевидные детали окружения (общий сервер)





Также рекомендуется к ознакомлению:
https://simonwillison.net/guides/agentic-engineering-patterns/